Tasca 2. Preparar una exposició oral per explicar l'anàlisi

Prepara una exposició per presentar el teu treball i explicar el procés seguit. L'objectiu és demostrar que comprens l'anàlisi i que saps adaptar el procediment de l'AC3 a un conjunt de dades diferent.

L'exposició ha d'incloure els aspectes següents:

1. **Presentació del conjunt de dades**

    - A quin sector pertany?

    El conjunt de dades pertany al sector de les llibreries. El fitxer 05_llibreria.csv conté 120 registres amb informació sobre llibres i articles classificats per gènere i sucursal.

    L'objectiu del treball és comprovar la qualitat d'aquesta informació, preparar les dades que compleixen les regles de validació i analitzar com es distribueixen els exemplars i les pàgines dels registres acceptats.

    - Què representa cada registre?

    Cada fila associa una denominació de llibre o article amb un gènere, una sucursal, una quantitat d'exemplars, un nombre de pàgines i una data.

    Per exemple, el primer registre correspon a un «Quadern», classificat com a «Educació», registrat a Vic, amb 47 exemplars, 18 pàgines i data del 3 d'abril de 2026.

    El dossier anomena aquestes files «moviments», però no especifica si són vendes, entrades d'estoc o altres operacions. Per això, durant l'anàlisi parlem d'exemplars registrats. A més, denominacions com «Quadern» o «Novel·la» no identifiquen un llibre concret.

- Quines són les columnes principals i què signifiquen?

Columna	Significat
titol	Denominació del llibre o article registrat.
genere	Gènere o classificació del registre.
sucursal	Sucursal on s'ha registrat el moviment.
exemplars	Quantitat d'exemplars associada al registre.
pagines	Nombre de pàgines del llibre o article.
data	Data associada al registre.

exemplars i pàgines han de representar **nombres enters estrictament positius**. Els tres camps descriptius són obligatoris i la data ha de ser vàlida segons el format establert.

Evidència al notebook

*Apartats **1. Presentació i objectius** i **2. Càrrega i exploració inicial**: descripció de les columnes, recompte de 120 registres i 6 columnes, i visualització de les primeres files.*

Proposta visual per a la diapositiva

*Mostrar **«120 registres · 6 columnes»**, una versió breu de la taula de camps i el primer registre com a exemple. La precisió sobre què significa «moviment» es pot explicar oralment.*

2. **Relació entre l'AC3 i l'AC4**

   - Quines fases de l'anàlisi de l'AC3 has reutilitzat?

Hem mantingut el mateix procés general: explorar el CSV, detectar incidències, definir les regles, netejar i validar les dades, separar els registres acceptats dels rebutjats i analitzar els resultats.

També hem conservat la documentació de les incidències, les comprovacions automàtiques i l'exportació dels resultats. Aquesta estructura ens permet seguir el recorregut des de les dades originals fins a les conclusions.

   - Quines parts del codi has pogut mantenir?

Hem reutilitzat l'enfocament de lectura amb csv.DictReader, que transforma cada fila en un diccionari. També els bucles per revisar registres, les llistes per separar els resultats i els diccionaris per acumular quantitats per grup.

Hem mantingut l'ús de strip() per eliminar espais dels extrems, els blocs try…except per gestionar conversions incorrectes i les assercions assert per comprovar la coherència.

Per exportar les dades, hem utilitzat csv.DictWriter. Per tant, hem conservat moltes eines i estructures, adaptant-ne els camps i les condicions.

   - Quines parts has hagut d'adaptar i per què?

Element	AC3	Adaptació a l'AC4
Camps descriptius	producte, categoria, ciutat	titol, genere, sucursal.
Camps numèrics	Unitats enteres i preu decimal.	Exemplars i pàgines: tots dos enters positius.
Conversió numèrica	Conversió d'unitats amb int() i de preus amb float().	Utilitzem Decimal per acceptar representacions com 3,0 i rebutjar fraccions sense truncar-les.
Dates	Comprovació amb datetime.strptime().	Afegim una comprovació del format exacte abans de validar el calendari.
Indicadors	Facturació, preus i imports.	Exemplars per gènere i sucursal i estadístiques de pàgines.
Lecturadel CSV	Codificació utf-8.	utf-8-sig per tractar la marca BOM del nou fitxer.

També hem incorporat fila_csv als registres nets i rebutjats per conservar la referència a l'origen, i hem exportat les files rebutjades a un fitxer propi.

L'adaptació principal ha estat canviar els criteris i els càlculs segons el significat de les dades, no només substituir els noms de les columnes.

Evidència al notebook

*Apartats **3.2 i 3.3**, amb les funcions i les seves proves; **4.1**, amb les regles; **5.3 i 5.4**, amb les comprovacions i exportacions; i **6**, amb els nous indicadors.*

Proposta visual per a la diapositiva

Mostrar tres canvis principals:

a) *Producte, categoria i ciutat → títol, gènere i sucursal.*
b) *Unitats i preu → exemplars i pàgines, tots dos enters.*
c) *Facturació → distribució d'exemplars i descripció de pàgines.*

3. **Característiques específiques de les dades**

- Quines diferències hi ha entre les variables de l'AC3 i les de l'AC4?

L'AC3 treballava amb vendes d'una botiga: producte, categoria, ciutat, unitats, preu unitari i data. Les unitats i el preu permetien calcular l'import de cada venda i la facturació.

A la llibreria tenim títol, gènere, sucursal, exemplars, pàgines i data.

No tenim preus i les pàgines expressen una característica del llibre o article, no un import. Per tant, aquests camps necessiten una interpretació diferent.

- Quins tipus de dades numèriques hi ha en el nou conjunt?

Variable	Què representa?	Condició de validació
exemplars	Quantitat d'exemplars associada al registre.	Enter estrictament positiu.
pagines	Nombre de pàgines del llibre o article.	Enter estrictament positiu.

Quan llegim el CSV, els valors arriben com a text. Després de validar-los, els convertim a int per poder calcular i comparar quantitats.

Acceptem una representació com 3,0 perquè equival exactament a l'enter 3. En canvi, rebutgem 2.5: no podem convertir-lo a 2 ni arrodonir-lo perquè alteraríem la dada.

- Com han condicionat aquestes diferències les operacions d'anàlisi?

Amb els exemplars, hem calculat totals i percentatges per gènere i sucursal. També hem creuat les dues classificacions per comprovar si la distribució dels gèneres varia entre sucursals.

Amb les pàgines, hem calculat mínim, màxim, mitjana, mediana i distribució per intervals, i hem comparat els resums per gènere. Cada registre té el mateix pes en aquests càlculs, independentment dels exemplars que contingui.

No hem traslladat la multiplicació d'unitats per preu de l'AC3 a exemplars per pàgines: aquesta operació mesuraria una altra cosa i no respondria a les preguntes que hem plantejat.

A més, titol conté denominacions generals com «Novel·la» o «Quadern». Per això, les estadístiques descriuen **registres**, sense considerar que cada fila identifiqui un llibre únic.

Evidència al notebook

*Apartat **2**, amb els tipus inicials; **3.2**, amb la conversió numèrica; **4.2**, amb els tipus de les dades netes; i **6**, amb les operacions d'anàlisi.*

Proposta visual per a la diapositiva

***Dues columnes: Exemplars:** quantitats → totals, percentatges i comparacions./ **Pàgines:** extensió → distribució i estadístiques descriptives.*

*Encara que totes dues variables siguin enteres, **el seu significat determina quins càlculs són útils**.*

4. **Problemes de qualitat detectats**

   - Quines incidències has identificat?

   Hem detectat quatre grups de problemes:

   - **Camps buits o amb només espais**, inclosos camps descriptius obligatoris.
   - **Valors numèrics incorrectes:** textos no interpretables, zeros, negatius i nombres amb part fraccionària.
   - **Dates invàlides:** dates impossibles, camps buits o formats no admesos.
   - **Formats normalitzables:** espais als extrems i representacions com `3,0`, que podem convertir sense alterar la informació.

   És important distingir els errors que impedeixen acceptar un registre dels problemes de format que podem corregir.

   - Com les has detectat amb Python?

Comprovació	Procediment
Camps buits	Comprovem si el valor és absent o queda buit després d'aplicar strip().
Nombres incorrectes	La funció converteix_enter_positiu() intenta interpretar el valor i comprova que sigui finit, positiu i sense part fraccionària.
Dates invàlides	La funció data_valida() comprova el format exacte AAAA-MM-DD i si la data existeix al calendari.
Formats normalitzables	Comparem el valor original amb la representació normalitzada que proposem.

En aquesta fase revisem els registres originals sense modificar-los. Les funcions es comproven prèviament amb exemples vàlids i invàlids.

- Pots mostrar exemples representatius?

Fila del CSV	Camp i valor original	Problema detectat
6	sucursal: " "	Només conté espais; falta informació obligatòria.
6	exemplars: "1O"	Conté la lletra O; no suposem que representa un zero.
32	exemplars: "2.5"	És numèric, però no és enter.
63	pagines: "-12.5"	És negatiu i té part fraccionària.
21	pagines: "aprox. 25"	No representa una quantitat exacta acceptable segons les regles.
21	data: "31/04/2025"	Format no admès i data impossible: abril té 30 dies.
74	titol: " Agenda "	Espais als extrems que podem eliminar.
63	exemplars: "3,0"	Representació normalitzable a l'enter 3.

Una fila pot tenir diversos problemes. Per exemple, la fila 6 té la sucursal buida i una quantitat d'exemplars no interpretable.

Evidència al notebook

*Apartat **3**, amb les deteccions, les proves de les funcions i els exemples; i **5.2**, amb casos complets i les decisions aplicades. El fitxer incidencies.csv conserva el detall de les incidències documentades durant la neteja.*

Proposta visual per a la diapositiva

(Com els detectem i per què no tots requereixen la mateixa resposta.)

" " → camp buit.

"1O" → nombre no interpretable.

"31/04/2025" → data incorrecta.

" Agenda " → format corregible.

5. **Decisions de neteja i validació**

   - Quines transformacions has aplicat?

Hem eliminat els espais dels extrems dels textos i normalitzat les representacions numèriques vàlides. Per exemple, " Agenda " passa a "Agenda" i "3,0" es converteix a l'enter 3.

Els camps exemplars i pagines es desen com a enters després de superar la validació. Les dates acceptades es conserven com a text en format AAAA-MM-DD, sense espais als extrems.

Les dades netes es construeixen en una llista nova. **El CSV i els registres originals no es modifiquen.**

   - Quins criteris has utilitzat per acceptar o rebutjar registres?

Un registre només s'accepta si compleix totes aquestes condicions:

- titol, genere i sucursal contenen informació després d'eliminar els espais dels extrems.
- exemplars i pagines representen enters estrictament positius.
- data té el format exacte establert i correspon a una data real.

Si falla qualsevol condició, rebutgem la fila completa i documentem els motius. Continuem revisant els altres camps encara que ja hàgim detectat un error, per no deixar incidències sense registrar.

Corregir un camp no implica acceptar tota la fila. A la fila 63, podem convertir "3,0" a 3, però rebutgem el registre perquè pagines conté "-12.5".

- Quines decisions has hagut de modificar respecte de l'AC3?

A l'AC3, el preu podia tenir decimals. Aquí, tant exemplars com pàgines han de ser enters: una quantitat positiva com `2.5` també s'ha de rebutjar.

Hem adaptat la conversió perquè accepti representacions equivalents a un enter, com `3,0`, sense truncar les que tenen part fraccionària.

En les dates, hem afegit una comprovació del format exacte abans de validar el calendari. Així rebutgem també representacions com `2025-1-4`, que no compleixen les dues xifres exigides per al mes i el dia.

- Com has evitat fer correccions arbitràries?

Hem limitat les correccions a transformacions que conserven la informació:

Decisió	**Justificació**
Eliminar espais dels extrems.	No canvia el contingut del text.
Convertir `3,0` a `3`.	Manté exactament la quantitat.
No convertir `10` a `10`.	No sabem si la lletra O és un error de transcripció.
No arrodonir `2.5`.	Alteraria la quantitat original.
No extreure `25` d'``aprox. 25`.	Convertiria una aproximació en un valor exacte.
No reconstruir dates impossibles ni omplir camps buits.	No disposem d'una font que indiqui el valor correcte.

Tampoc hem eliminat valors positius poc habituals, com una pàgina, sense una regla documentada que ho justifiqui. Hem assenyalat aquesta limitació.

Evidència al notebook

*Apartat **4**, amb les regles i el procés; **5.2**, amb exemples; i **5.3**, amb les comprovacions de coherència. Les incidències conserven la fila, el camp, el valor original i l'acció o motiu.*

Proposta visual per a la diapositiva

Fila 74: *espais eliminats → registre acceptat.*

Fila 63: *exemplars normalitzats, però pàgines invàlides → registre rebutjat.*

Acceptem només quan tots els camps compleixen les regles i podem justificar cada transformació.

6. **Resultats del procés de neteja**

    - Quants registres hi havia inicialment?

    - Quants s'han acceptat i quants s'han rebutjat?
    - Quines incidències han estat més freqüents?
    - Què indiquen aquests resultats sobre la qualitat de les dades?
7. **Anàlisi de les dades netes**
    - Quins indicadors has calculat i per què?
    - Quines agrupacions o comparacions has fet?
    - Quins resultats consideres més rellevants?
    - Com interpretes les taules o els gràfics que presentes?
8. **Conclusions i possibles millores**
    - Què has après sobre el conjunt de dades?
    - Quines limitacions té l'anàlisi?
    - Quines mesures proposaries per millorar la qualitat de les dades en origen?