Tasca 2. Preparar una exposició oral per explicar l'anàlisi

Guió de l'exposició — Neteja i anàlisi de dades d'una llibreria

Partim d'un fitxer de 120 registres de la llibreria que conté problemes de qualitat. El nostre objectiu és identificar-los, justificar quines correccions podem aplicar i separar els registres que no compleixen les regles. Després utilitzem les dades acceptades per descriure la distribució dels exemplars per gènere i sucursal i estudiar les pàgines. L'anàlisi permet observar diferències en el fitxer, però no explicar-ne les causes ni prendre decisions comercials sense informació addicional.

1. **Presentació del conjunt de dades**

    - A quin sector pertany?

El conjunt de dades pertany al sector de les llibreries. El fitxer 05_llibreria.csv conté 120 registres amb informació sobre llibres i articles classificats per gènere i sucursal.

L'objectiu del treball és comprovar la qualitat d'aquesta informació, preparar les dades que compleixen les regles de validació i analitzar com es distribueixen els exemplars i les pàgines dels registres acceptats.

    - Què representa cada registre?

Cada fila associa una denominació de llibre o article amb un gènere, una sucursal, una quantitat d'exemplars, un nombre de pàgines i una data.

Per exemple, el primer registre correspon a un «Quadern», classificat com a «Educació», registrat a Vic, amb 47 exemplars, 18 pàgines i data del 3 d'abril de 2026.

El dossier anomena aquestes files «moviments», però no especifica si són vendes, entrades d'estoc o altres operacions. Per això, durant l'anàlisi parlem d'exemplars registrats. A més, denominacions com «Quadern» o «Novel·la» no identifiquen un llibre concret.

- Quines són les columnes principals i què signifiquen?

Columna	Significat
titol	Denominació del llibre o article registrat.
genere	Gènere o classificació del registre.
sucursal	Sucursal on s'ha registrat el moviment.
exemplars	Quantitat d'exemplars associada al registre.
pagines	Nombre de pàgines del llibre o article.
data	Data associada al registre.

exemplars i pàgines han de representar **nombres enters estrictament positius**. Els tres camps descriptius són obligatoris i la data ha de ser vàlida segons el format establert.

Evidència al notebook

*Apartats **1. Presentació i objectius** i **2. Càrrega i exploració inicial**: descripció de les columnes, recompte de 120 registres i 6 columnes, i visualització de les primeres files.*

Proposta visual per a la diapositiva

*Mostrar **«120 registres · 6 columnes»**, una versió breu de la taula de camps i el primer registre com a exemple. La precisió sobre què significa «moviment» es pot explicar oralment.*

2. **Relació entre l'AC3 i l'AC4**

   - Quines fases de l'anàlisi de l'AC3 has reutilitzat?

Hem mantingut el mateix procés general: explorar el CSV, detectar incidències, definir les regles, netejar i validar les dades, separar els registres acceptats dels rebutjats i analitzar els resultats.

També hem conservat la documentació de les incidències, les comprovacions automàtiques i l'exportació dels resultats. Aquesta estructura ens permet seguir el recorregut des de les dades originals fins a les conclusions.

   - Quines parts del codi has pogut mantenir?

Hem reutilitzat l'enfocament de lectura amb csv.DictReader, que transforma cada fila en un diccionari. També els bucles per revisar registres, les llistes per separar els resultats i els diccionaris per acumular quantitats per grup.

Hem mantingut l'ús de strip() per eliminar espais dels extrems, els blocs try…except per gestionar conversions incorrectes i les assercions assert per comprovar la coherència.

Per exportar les dades, hem utilitzat csv.DictWriter. Per tant, hem conservat moltes eines i estructures, adaptant-ne els camps i les condicions.

   - Quines parts has hagut d'adaptar i per què?

Element	AC3	Adaptació a l'AC4
Camps descriptius	producte, categoria, ciutat	titol, genere, sucursal.
Camps numèrics	Unitats enteres i preu decimal.	Exemplars i pàgines: tots dos enters positius.
Conversió numèrica	Conversió d'unitats amb int() i de preus amb float().	Utilitzem Decimal per acceptar representacions com 3,0 i rebutjar fraccions sense truncar-les.
Dates	Comprovació amb datetime.strptime().	Afegim una comprovació del format exacte abans de validar el calendari.
Indicadors	Facturació, preus i imports.	Exemplars per gènere i sucursal i estadístiques de pàgines.
Lecturadel CSV	Codificació utf-8.	utf-8-sig per tractar la marca BOM del nou fitxer.

També hem incorporat fila_csv als registres nets i rebutjats per conservar la referència a l'origen, i hem exportat les files rebutjades a un fitxer propi.

L'adaptació principal ha estat canviar els criteris i els càlculs segons el significat de les dades, no només substituir els noms de les columnes.

Evidència al notebook

*Apartats **3.2 i 3.3**, amb les funcions i les seves proves; **4.1**, amb les regles; **5.3 i 5.4**, amb les comprovacions i exportacions; i **6**, amb els nous indicadors.*

Proposta visual per a la diapositiva

Mostrar tres canvis principals:

a) Producte, categoria i ciutat → títol, gènere i sucursal.
b) Unitats i preu → exemplars i pàgines, tots dos enters.
c) Facturació → distribució d'exemplars i descripció de pàgines.

3. **Característiques específiques de les dades**

- Quines diferències hi ha entre les variables de l'AC3 i les de l'AC4?

L'AC3 treballava amb vendes d'una botiga: producte, categoria, ciutat, unitats, preu unitari i data. Les unitats i el preu permetien calcular l'import de cada venda i la facturació.

A la llibreria tenim títol, gènere, sucursal, exemplars, pàgines i data.

No tenim preus i les pàgines expressen una característica del llibre o article, no un import. Per tant, aquests camps necessiten una interpretació diferent.

- Quins tipus de dades numèriques hi ha en el nou conjunt?

Variable	Què representa?	Condició de validació
exemplars	Quantitat d'exemplars associada al registre.	Enter estrictament positiu.
pagines	Nombre de pàgines del llibre o article.	Enter estrictament positiu.

Quan llegim el CSV, els valors arriben com a text. Després de validar-los, els convertim a int per poder calcular i comparar quantitats.

Acceptem una representació com 3,0 perquè equival exactament a l'enter 3. En canvi, rebutgem 2.5: no podem convertir-lo a 2 ni arrodonir-lo perquè alteraríem la dada.

- Com han condicionat aquestes diferències les operacions d'anàlisi?

Amb els exemplars, hem calculat totals i percentatges per gènere i sucursal. També hem creuat les dues classificacions per comprovar si la distribució dels gèneres varia entre sucursals.

Amb les pàgines, hem calculat mínim, màxim, mitjana, mediana i distribució per intervals, i hem comparat els resums per gènere. Cada registre té el mateix pes en aquests càlculs, independentment dels exemplars que contingui.

No hem traslladat la multiplicació d'unitats per preu de l'AC3 a exemplars per pàgines: aquesta operació mesuraria una altra cosa i no respondria a les preguntes que hem plantejat.

A més, titol conté denominacions generals com «Novel·la» o «Quadern». Per això, les estadístiques descriuen **registres**, sense considerar que cada fila identifiqui un llibre únic.

Evidència al notebook

*Apartat **2**, amb els tipus inicials; **3.2**, amb la conversió numèrica; **4.2**, amb els tipus de les dades netes; i **6**, amb les operacions d'anàlisi.*

Proposta visual per a la diapositiva

***Dues columnes: Exemplars:** quantitats → totals, percentatges i comparacions./ **Pàgines:** extensió → distribució i estadístiques descriptives.*

*Encara que totes dues variables siguin enteres, **el seu significat determina quins càlculs són útils**.*

4. **Problemes de qualitat detectats**

   - Quines incidències has identificat?

Hem detectat quatre grups de problemes:

- **Camps buits o amb només espais**, inclosos camps descriptius obligatoris.
- **Valors numèrics incorrectes:** textos no interpretables, zeros, negatius i nombres amb part fraccionària.
- **Dates invàlides:** dates impossibles, camps buits o formats no admesos.
- **Formats normalitzables:** espais als extrems i representacions com `3,0`, que podem convertir sense alterar la informació.

És important distingir els errors que impedeixen acceptar un registre dels problemes de format que podem corregir.

   - Com les has detectat amb Python?

Comprovació	Procediment
Camps buits	Comprovem si el valor és absent o queda buit després d'aplicar strip().
Nombres incorrectes	La funció converteix_enter_positiu() intenta interpretar el valor i comprova que sigui finit, positiu i sense part fraccionària.
Dates invàlides	La funció data_valida() comprova el format exacte AAAA-MM-DD i si la data existeix al calendari.
Formats normalitzables	Comparem el valor original amb la representació normalitzada que proposem.

En aquesta fase revisem els registres originals sense modificar-los. Les funcions es comproven prèviament amb exemples vàlids i invàlids.

- Pots mostrar exemples representatius?

Fila del CSV	Camp i valor original	Problema detectat
6	sucursal: " "	Només conté espais; falta informació obligatòria.
6	exemplars: "1O"	Conté la lletra O; no suposem que representa un zero.
32	exemplars: "2.5"	És numèric, però no és enter.
63	pagines: "-12.5"	És negatiu i té part fraccionària.
21	pagines: "aprox. 25"	No representa una quantitat exacta acceptable segons les regles.
21	data: "31/04/2025"	Format no admès i data impossible: abril té 30 dies.
74	titol: " Agenda "	Espais als extrems que podem eliminar.
63	exemplars: "3,0"	Representació normalitzable a l'enter 3.

Una fila pot tenir diversos problemes. Per exemple, la fila 6 té la sucursal buida i una quantitat d'exemplars no interpretable.

Evidència al notebook

*Apartat **3**, amb les deteccions, les proves de les funcions i els exemples; i **5.2**, amb casos complets i les decisions aplicades. El fitxer incidencies.csv conserva el detall de les incidències documentades durant la neteja.*

Proposta visual per a la diapositiva

(Com els detectem i per què no tots requereixen la mateixa resposta.)

" " → camp buit.

"1O" → nombre no interpretable.

"31/04/2025" → data incorrecta.

" Agenda " → format corregible.

5. **Decisions de neteja i validació**

   - Quines transformacions has aplicat?

Hem eliminat els espais dels extrems dels textos i normalitzat les representacions numèriques vàlides. Per exemple, " Agenda " passa a "Agenda" i "3,0" es converteix a l'enter 3.

Els camps exemplars i pagines es desen com a enters després de superar la validació. Les dates acceptades es conserven com a text en format AAAA-MM-DD, sense espais als extrems.

Les dades netes es construeixen en una llista nova. **El CSV i els registres originals no es modifiquen.**

   - Quins criteris has utilitzat per acceptar o rebutjar registres?

Un registre només s'accepta si compleix totes aquestes condicions:

- titol, genere i sucursal contenen informació després d'eliminar els espais dels extrems.
- exemplars i pagines representen enters estrictament positius.
- data té el format exacte establert i correspon a una data real.

Si falla qualsevol condició, rebutgem la fila completa i documentem els motius. Continuem revisant els altres camps encara que ja hàgim detectat un error, per no deixar incidències sense registrar.

Corregir un camp no implica acceptar tota la fila. A la fila 63, podem convertir "3,0" a 3, però rebutgem el registre perquè pagines conté "-12.5".

- Quines decisions has hagut de modificar respecte de l'AC3?

A l'AC3, el preu podia tenir decimals. Aquí, tant exemplars com pàgines han de ser enters: una quantitat positiva com `2.5` també s'ha de rebutjar.

Hem adaptat la conversió perquè accepti representacions equivalents a un enter, com `3,0`, sense truncar les que tenen part fraccionària.

En les dates, hem afegit una comprovació del format exacte abans de validar el calendari. Així rebutgem també representacions com `2025-1-4`, que no compleixen les dues xifres exigides per al mes i el dia.

- Com has evitat fer correccions arbitràries?

Hem limitat les correccions a transformacions que conserven la informació:

Decisió	**Justificació**
Eliminar espais dels extrems.	No canvia el contingut del text.
Convertir 3,0 a 3.	Manté exactament la quantitat.
No convertir 1O a 10.	No sabem si la lletra O és un error de transcripció.
No arrodonir 2.5.	Alteraria la quantitat original.
No extreure 25 d'``aprox. 25`.	Convertiria una aproximació en un valor exacte.
No reconstruir dates impossibles ni omplir camps buits.	No disposem d'una font que indiqui el valor correcte.

Tampoc hem eliminat valors positius poc habituals, com una pàgina, sense una regla documentada que ho justifiqui. Hem assenyalat aquesta limitació.

Evidència al notebook

*Apartat **4**, amb les regles i el procés; **5.2**, amb exemples; i **5.3**, amb les comprovacions de coherència. Les incidències conserven la fila, el camp, el valor original i l'acció o motiu.*

Proposta visual per a la diapositiva

Fila 74: *espais eliminats → registre acceptat.*

Fila 63: *exemplars normalitzats, però pàgines invàlides → registre rebutjat.*

Acceptem només quan tots els camps compleixen les regles i podem justificar cada transformació.

6. **Resultats del procés de neteja**

   - Quants registres hi havia inicialment?

El CSV original contenia **120 registres**, sense comptar la capçalera.

   - Quants s'han acceptat i quants s'han rebutjat?

Resultat	Registres	Percentatge
Acceptats	90	75 %
Rebutjats	30	25 %
Total	**120**	**100 %**

Els acceptats compleixen totes les regles després de les normalitzacions permeses. Els rebutjats incompleixen almenys una condició.

Hem comprovat que totes les files originals quedin classificades una sola vegada, sense omissions ni duplicacions.

- Quines incidències han estat més freqüents?

Hem documentat **58 incidències: 49 motius de rebuig i 9 correccions de format**.

Camp	Motius de rebuig	Correccions
titol	4	5
genere	5	3
sucursal	5	0
exemplars	11	1
pagines	12	0
data	12	0
Total	**49**	**9**

Pàgines i data són els camps amb més motius de rebuig, amb 12 cadascun, seguits d'exemplars, amb 11. Les correccions corresponen a vuit eliminacions d'espais en camps descriptius i una normalització numèrica.

Els 49 motius no equivalen a 49 registres rebutjats: **una mateixa fila pot tenir diversos errors**. Igualment, un registre pot contenir un camp corregible i un altre que provoqui el rebuig.

Aquest recompte identifica els camps més afectats; no desglossa els errors numèrics entre negatius, fraccions o textos no interpretables.

- Què indiquen aquests resultats sobre la qualitat de les dades?

Una quarta part de les files no es pot incorporar a l'anàlisi segons les regles establertes. Això mostra que els problemes del fitxer no es resolen únicament eliminant espais o normalitzant formats.

Les incidències detectades justifiquen millorar els controls d'entrada, especialment dels nombres, les dates i els camps obligatoris.

Els 90 registres acceptats permeten continuar l'anàlisi, però **superar les regles no garanteix que la informació sigui certa en origen**. A més, els registres exclosos podrien afectar les comparacions entre gèneres o sucursals.

Evidència al notebook

*Apartats **4**, amb el balanç de la neteja, i **5.1 i 5.3**, amb el recompte d'incidències i les comprovacions. Els CSV exportats permeten consultar el detall complet.*

Proposta visual per a la diapositiva

Mostrar **120 inicials → 90 acceptats i 30 rebutjats**, destacant el **25 % de rebutjos**. Acompanyar-ho d'una taula breu dels camps més afectats: pàgines, data i exemplars.

Explicar diferència entre **registre rebutjat, motiu de rebuig i correcció de format**.

7. **Anàlisi de les dades netes**

- Quins indicadors has calculat i per què?

Hem analitzat exclusivament els **90 registres acceptats**.

Indicador	Per què l'hem calculat?
Total d'exemplars	Conèixer la quantitat acumulada en els registres acceptats.
Exemplars i percentatges per gènere i sucursal	Comparar el volum i el pes de cada grup.
Nombre de registres per grup	Distingir la quantitat de files de la quantitat d'exemplars.
Mínim, màxim, mitjana i mediana de pàgines	Descriure els extrems i els valors centrals.
Registres per intervals de pàgines	Observar com es reparteixen els valors.

- Quines agrupacions o comparacions has fet?

Hem agrupat els exemplars **per gènere i per sucursal**, i hem creuat totes dues variables per veure si el gènere predominant canvia entre sucursals.

També hem comparat les estadístiques de pàgines per gènere. En aquests càlculs, cada registre té el mateix pes, independentment dels exemplars que contingui.

- Quins resultats consideres més rellevants?

Els registres acceptats acumulen **3.377 exemplars**.

- **Coneixement** concentra més exemplars globalment: 831, el **24,61 %**.
- **Vic** és la sucursal amb més exemplars registrats: 1.032, el **30,56 %**.
- El gènere predominant varia segons la sucursal:

Sucursal	*Gènere amb més exemplars*	*Exemplars*	*Percentatge dins de la sucursal*
Barcelona	Coneixement	159	24,88 %
Girona	Còmic	114	32,85 %
Manresa	Coneixement	252	29,68 %
Tarragona	Coneixement	120	23,53 %
Vic	Educació	410	39,73 %

A Tarragona, Coneixement supera Infantil només en **dos exemplars: 120 davant de 118**. Per tant, el primer lloc no implica una diferència àmplia.

També observem que **Manresa té més registres que Vic —22 davant de 21—, però menys exemplars**. Comptar files no és suficient per comparar quantitats.

Pel que fa a les pàgines, els valors van d'**1 a 80**, amb una mitjana de **37,12** i una mediana de **38**. L'interval d'1 a 20 pàgines és el més freqüent, amb 30 registres, el 33,33 %.

- Com interpretes les taules o els gràfics que presentes?

Les taules d'exemplars mostren com es distribueixen les quantitats registrades. El creuament permet veure que **el predomini global de Coneixement no es repeteix a totes les sucursals**.

Els percentatges globals es calculen sobre els 3.377 exemplars. En canvi, els percentatges de la taula anterior es calculen sobre el total de **cada sucursal**.

Les estadístiques de pàgines descriuen els registres, no llibres únics ni exemplars individuals. Ficció té la mitjana més alta i Papereria la més baixa, però els rangs se solapen: no podem afirmar que tots els articles d'un gènere siguin més llargs que els d'un altre.

Finalment, aquests resultats **no demostren vendes, preferències dels clients ni millor rendiment comercial**, perquè el fitxer no defineix el tipus d'operació.

Evidència al notebook

*Apartat **6. Anàlisi de les dades netes**, amb les cinc anàlisis, les interpretacions i les comprovacions dels totals.*

Proposta visual per a les diapositives

Dividir aquest bloc en dues diapositives:

- *Exemplars: total global, distribució per gènere i diferències entre sucursals.*
- *Pàgines: mínim, màxim, mitjana, mediana i distribució per intervals.*

8. **Conclusions i possibles millores**

   - Què has après sobre el conjunt de dades?

Hem comprovat que cal revisar les dades abans d'analitzar-les: dels **120 registres originals, 90 compleixen les regles i 30 es rebutgen**.

Els registres acceptats permeten observar que **la distribució dels exemplars varia entre sucursals**. Coneixement predomina globalment, però a Girona destaca Còmic i a Vic, Educació. Per tant, el total global no descriu per igual tots els establiments.

També hem après que el significat de cada variable determina els càlculs: els exemplars expressen quantitats, mentre que les pàgines descriuen l'extensió dels articles registrats.

   - Quines limitacions té l'anàlisi?

Només analitzem els 90 registres acceptats. Els rebutjats podrien modificar les comparacions, i no hem estudiat si afecten especialment algun gènere o sucursal.

El tipus d'operació no està definit. No podem interpretar els exemplars com a vendes ni deduir preferències dels clients.

No identifiquem llibres únics. Denominacions com «Novel·la» o «Quadern» poden correspondre a articles diferents.

Validar no garanteix la veracitat. Un valor pot complir les regles i continuar sent incorrecte en origen. Per comprovar-ho necessitaríem una font de contrast.

   - Quines mesures proposaries per millorar la qualitat de les dades en origen?

Mesura	Problema que ajudaria a evitar
Exigir contingut als camps obligatoris, després d'eliminar espais.	Títols, gèneres i sucursals buits.
Validar enters estrictament positius en introduir exemplars i pàgines.	Textos no numèrics, zeros, negatius i fraccions.
Utilitzar un selector de dates i un format únic.	Dates impossibles i formats inconsistents.
Documentar què representa cada fila.	Interpretacions ambigües dels exemplars registrats.
Incorporar un identificador de llibre i edició.	Confusió entre articles amb denominacions generals.

CONCLUSIÓ FINAL

Hem revisat la qualitat dels 120 registres de la llibreria i n'hem acceptat 90 i rebutjat 30 segons les regles establertes. Hem documentat 49 motius de rebuig i 9 correccions de format. Aquests resultats mostren la necessitat de millorar els controls d'entrada de dades, especialment en els camps de pàgines, dates i exemplars.

Els registres acceptats mostren que la distribució dels exemplars per gènere varia entre sucursals. Coneixement acumula més exemplars globalment, però a Girona destaca Còmic i a Vic, Educació. Per tant, els totals globals amaguen diferències que podem observar quan analitzem cada sucursal per separat.

Aquestes conclusions descriuen únicament els registres acceptats. Els 30 rebutjats podrien modificar les comparacions. A més, com que el fitxer no defineix el tipus d'operació de cada fila, no podem deduir vendes, preferències dels clients ni necessitats d'estoc.

La validació comprova els camps obligatoris, els formats, els enters positius i les dates, però no contrasta la informació amb un catàleg real. Per això, acceptar un registre no garanteix que la classificació o el nombre de pàgines siguin correctes en origen. Aquests valors requeririen una font de referència per confirmar-los o corregir-los.

El treball ens ha permès identificar problemes de qualitat, preparar un conjunt de dades analitzable segons criteris explícits i descriure'n els resultats sense atribuir-los significats que no podem demostrar.